



# 矩阵求导



覃雄派



# 提纲

- 矩阵求导入门
- 矩阵求导实例



矩阵求导



# 矩阵求导

- 矩阵求导参考资料

## The Matrix Cookbook

[ <http://matrixcookbook.com> ]

Kaare Brandt Petersen  
Michael Syskind Pedersen

VERSION: NOVEMBER 15, 2012

这里先进行简单入门，然后直接使用该cook book的一些结论

<https://www.math.uwaterloo.ca/~hwolkowi/matrixcookbook.pdf>

# 矩阵求导





# 矩阵求导

- 矩阵求导入门

$$\mathbf{x} = \begin{bmatrix} 1 \\ x_1 \\ x_2 \\ \vdots \\ x_d \end{bmatrix}$$

$$\boldsymbol{\theta} = \begin{bmatrix} \theta_0 \\ \theta_1 \\ \theta_2 \\ \vdots \\ \theta_d \end{bmatrix}$$

按照“列”组织向量

$$\mathbf{x}^T \boldsymbol{\theta} = [1 \quad x_1 \quad x_2 \quad \dots \quad x_d] \begin{bmatrix} \theta_0 \\ \theta_1 \\ \theta_2 \\ \vdots \\ \theta_d \end{bmatrix} = \theta_0 + x_1 \theta_1 + x_2 \theta_2 + \dots + x_d \theta_d$$

向量点乘

# 矩阵求导

- 矩阵求导入门

$$\mathbf{x} = \begin{bmatrix} 1 \\ x_1 \\ x_2 \\ \vdots \\ x_d \end{bmatrix}$$

$$\boldsymbol{\theta} = \begin{bmatrix} \theta_0 \\ \theta_1 \\ \theta_2 \\ \vdots \\ \theta_d \end{bmatrix}$$

$$\mathbf{x}^T \boldsymbol{\theta} = [1 \quad x_1 \quad x_2 \quad \dots \quad x_d] \begin{bmatrix} \theta_0 \\ \theta_1 \\ \theta_2 \\ \vdots \\ \theta_d \end{bmatrix} = \theta_0 + x_1 \theta_1 + x_2 \theta_2 + \dots + x_d \theta_d$$

1.  $\theta_0 + x_1 \theta_1 + x_2 \theta_2 + \dots + x_d \theta_d$   
对  $\theta_0$ 、 $\theta_1$ 、 $\theta_2$ 、 $\dots$ 、 $\theta_d$   
求导

2. 得到

$$1 \quad x_1 \quad x_2 \quad \dots \quad x_d$$

3. 按照列向量来组织为

$$\begin{bmatrix} 1 \\ x_1 \\ x_2 \\ \vdots \\ x_d \end{bmatrix}$$

# 矩阵求导

- 矩阵求导入门

$$\mathbf{x} = \begin{bmatrix} 1 \\ x_1 \\ x_2 \\ \vdots \\ x_d \end{bmatrix}$$

$$\boldsymbol{\theta} = \begin{bmatrix} \theta_0 \\ \theta_1 \\ \theta_2 \\ \vdots \\ \theta_d \end{bmatrix}$$

$$\mathbf{x}^T \boldsymbol{\theta} = [1 \quad x_1 \quad x_2 \quad \dots \quad x_d] \begin{bmatrix} \theta_0 \\ \theta_1 \\ \theta_2 \\ \vdots \\ \theta_d \end{bmatrix} = \theta_0 + x_1 \theta_1 + x_2 \theta_2 + \dots + x_d \theta_d$$

1.  $\theta_0 + x_1 \theta_1 + x_2 \theta_2 + \dots + x_d \theta_d$   
对  $\theta_0, \theta_1, \theta_2, \dots, \theta_d$   
求导

2. 得到

$$1 \quad x_1 \quad x_2 \quad \dots \quad x_d$$

3. 按照列向量来组织为

$$\begin{bmatrix} 1 \\ x_1 \\ x_2 \\ \vdots \\ x_d \end{bmatrix}$$



$$\frac{\partial \mathbf{x}^T \boldsymbol{\theta}}{\partial \boldsymbol{\theta}} = \frac{\partial \boldsymbol{\theta}^T \mathbf{x}}{\partial \boldsymbol{\theta}} = \mathbf{x}$$

第一个重要公式

# 矩阵求导

- 矩阵求导入门

$$\mathbf{x} = \begin{bmatrix} 1 \\ x_1 \\ x_2 \\ \vdots \\ x_d \end{bmatrix}$$

$$\boldsymbol{\theta} = \begin{bmatrix} \theta_0 \\ \theta_1 \\ \theta_2 \\ \vdots \\ \theta_d \end{bmatrix}$$

$$\mathbf{x}^T \boldsymbol{\theta} = [1 \quad x_1 \quad x_2 \quad \dots \quad x_d] \begin{bmatrix} \theta_0 \\ \theta_1 \\ \theta_2 \\ \vdots \\ \theta_d \end{bmatrix} = \theta_0 + x_1 \theta_1 + x_2 \theta_2 + \dots + x_d \theta_d$$

$\theta_0 + x_1 \theta_1 + x_2 \theta_2 + \dots + x_d \theta_d$   
对  $\theta_0, \theta_1, \theta_2, \dots, \theta_d$   
求导得到

$$1 \quad x_1 \quad x_2 \quad \dots \quad x_d$$

按照列向量来组织为  $\begin{bmatrix} 1 \\ x_1 \\ x_2 \\ \vdots \\ x_d \end{bmatrix}$

$\mathbf{x}$  列向量

$\mathbf{a}$  列向量

$$\frac{\partial \mathbf{a}^T \mathbf{x}}{\partial \mathbf{x}} = \frac{\partial \mathbf{x}^T \mathbf{a}}{\partial \mathbf{x}} = \mathbf{a}$$



# 矩阵求导



# 矩阵求导

- 矩阵求导入门

$\mathbf{x}$  列向量

$\mathbf{a}$  列向量

$$\frac{\partial \mathbf{a}^T \mathbf{x}}{\partial \mathbf{x}} = \frac{\partial \mathbf{x}^T \mathbf{a}}{\partial \mathbf{x}} = \mathbf{a}$$



$\mathbf{b}^T \mathbf{A}$

看作一个整体

$$\frac{\partial \mathbf{b}^T \mathbf{A} \mathbf{x}}{\partial \mathbf{x}} = \mathbf{A}^T \mathbf{b}$$



# 矩阵求导

- 矩阵求导入门

$\mathbf{x}$  列向量  
 $\mathbf{a}$  列向量

$$\frac{\partial \mathbf{a}^T \mathbf{x}}{\partial \mathbf{x}} = \frac{\partial \mathbf{x}^T \mathbf{a}}{\partial \mathbf{x}} = \mathbf{a}$$

有两个 $\mathbf{x}$ ，分别求导，累加

$$\mathbf{x}^T \mathbf{A} \mathbf{x}$$

$$\mathbf{x}^T \mathbf{A} \mathbf{x}$$

$$\frac{\partial \mathbf{x}^T \mathbf{A} \mathbf{x}}{\partial \mathbf{x}} = \mathbf{A} \mathbf{x} + \mathbf{A}^T \mathbf{x}$$



# 矩阵求导

- 矩阵求导入门

$\mathbf{x}$  列向量  
 $\mathbf{a}$  列向量

$$\frac{\partial \mathbf{a}^T \mathbf{x}}{\partial \mathbf{x}} = \frac{\partial \mathbf{x}^T \mathbf{a}}{\partial \mathbf{x}} = \mathbf{a}$$

有两个 $\mathbf{x}$ ，分别求导，累加

$$\mathbf{x}^T \mathbf{A} \mathbf{x}$$

$$\mathbf{x}^T \mathbf{A} \mathbf{x}$$

$$2\mathbf{A}\mathbf{x}$$

如果 $\mathbf{A}$ 是对称矩阵

$$\frac{\partial \mathbf{x}^T \mathbf{A} \mathbf{x}}{\partial \mathbf{x}} = \mathbf{A}\mathbf{x} + \mathbf{A}^T \mathbf{x}$$



# 矩阵求导



# 矩阵求导

在SVM的梯度下降法求解过程中用到

## • Hinge loss $\rightarrow$ SVM

- $\max(0, 1 - y_i w^T x_i) + \frac{\lambda}{2} ||w||^2$ 
  - 对 $w$ 求导
  - 注意 $y_i$ 是标量,  $x_i$ 是一个列向量,  $w$ 是一个列向量 (权重)
  - $||w||^2$ 为 $w$ 和自己点乘, 即 $w^T w$
- 分两个部分

$$- \frac{\partial}{\partial w} [\max(0, 1 - y_i w^T x_i)] = \begin{cases} -y_i x_i, & \text{if } 1 - y_i w^T x_i \geq 0 \\ 0, & \text{if } 1 - y_i w^T x_i < 0 \end{cases}$$



$$\frac{\partial a^T x}{\partial x} = \frac{\partial x^T a}{\partial x} = a$$

$$- \frac{\partial}{\partial w} \left[ \frac{\lambda}{2} ||w||^2 \right] = \frac{\partial}{\partial w} \left( \frac{\lambda}{2} w^T w \right) = \frac{\lambda}{2} (w + w) = \lambda w$$



$$\frac{\partial a^T x}{\partial x} = \frac{\partial x^T a}{\partial x} = a$$

分别对 $w^T w$ 的两个 $w$ 求导, 再加起来

# 矩阵求导







# 矩阵求导

当 $\xi_i \geq 0$ 时

$$1 - y_i(w^T K(x, x_i) + b) > 0$$

- Hinge loss  $\rightarrow$  kernelized SVM

$$- \frac{1}{2} w^T K(x, x^T) w + C \sum_{i=1}^n \max(0, 1 - y_i(w^T K(x, x_i) + b))$$

- 对 $w$ 求导, 对 $b$ 求导

$$- \frac{\partial L}{\partial w} = K(x, x^T) w - C \sum_{i=1, \xi_i \geq 0}^n y_i K(x, x_i)$$



$$\frac{\partial \mathbf{x}^T \mathbf{B} \mathbf{x}}{\partial \mathbf{x}} = (\mathbf{B} + \mathbf{B}^T) \mathbf{x}$$

$K(x, x^T)$ 为一个对称矩阵



$$\frac{\partial \mathbf{x}^T \mathbf{a}}{\partial \mathbf{x}} = \mathbf{a}$$

把 $K(x, x_i)$ 看作一个列向量

$$- \frac{\partial L}{\partial b} = -C \sum_{i=1, \xi_i \geq 0}^n y_i$$

- 注意 $b$ 是标量,  $y_i$ 是标量



# 矩阵求导



# 矩阵求导

- 一元/多元线性回归的解析解

$$- \frac{1}{2n} (\mathbf{Y} - \mathbf{X}\boldsymbol{\theta})^T (\mathbf{Y} - \mathbf{X}\boldsymbol{\theta}) = \frac{1}{2n} (\mathbf{Y}^T - \boldsymbol{\theta}^T \mathbf{X}^T)(\mathbf{Y} - \mathbf{X}\boldsymbol{\theta})$$

- 对 $\boldsymbol{\theta}$ 求导

$$- \frac{1}{2n} (\mathbf{Y}^T \mathbf{Y} - \mathbf{Y}^T \mathbf{X}\boldsymbol{\theta} - \boldsymbol{\theta}^T \mathbf{X}^T \mathbf{Y} + \boldsymbol{\theta}^T \mathbf{X}^T \mathbf{X}\boldsymbol{\theta})$$

$$\frac{\partial \mathbf{a}^T \mathbf{x}}{\partial \mathbf{x}} = \mathbf{a}$$

$$\frac{\partial \mathbf{x}^T \mathbf{a}}{\partial \mathbf{x}} = \mathbf{a}$$

分别对两个求导

$$\boldsymbol{\theta}^T \mathbf{X}^T \mathbf{X} \boldsymbol{\theta}$$

$$\boldsymbol{\theta}^T \mathbf{X}^T \mathbf{X} \boldsymbol{\theta}$$

$$- \frac{1}{2n} (0 - \mathbf{X}^T \mathbf{Y} - \mathbf{X}^T \mathbf{Y} + \mathbf{X}^T \mathbf{X}\boldsymbol{\theta} + \mathbf{X}^T \mathbf{X}\boldsymbol{\theta})$$

$$\frac{\partial \mathbf{x}^T \mathbf{a}}{\partial \mathbf{x}} = \frac{\partial \mathbf{a}^T \mathbf{x}}{\partial \mathbf{x}} = \mathbf{a}$$

# 矩阵求导





# 矩阵求导

X  
10元素  
 $A^{[0]}$

$W^{[1]}$ 、 $b^{[1]}$

隐藏层  
64神经元  
 $Z^{[1]} \rightarrow A^{[1]}$

$W^{[2]}$ 、 $b^{[2]}$

输出层  
1个神经元  
 $Z^{[2]} \rightarrow A^{[2]}$

损失函数J  
二元交叉熵

## 神经网络

- (1)  $Z^{[1]} = W^{[1]}X + b^{[1]} = (64*10)(10*1) + (64*1) = (64*1)$
- (2)  $A^{[1]} = \sigma(Z^{[1]}) = (64*1)$
- (3)  $Z^{[2]} = W^{[2]}A^{[1]} + b^{[2]} = (1*64)(64*1) + (1*1) = (1*1)$
- (4)  $\hat{y} = A^{[2]} = \sigma(Z^{[2]}) = (1*1)$
- 处理过程  $A^{[0]} \rightarrow Z^{[1]} \rightarrow A^{[1]} \rightarrow Z^{[2]} \rightarrow A^{[2]}$
- X即 $A^{[0]}$

有1个样本，每个样本为 $10 \times 1$ 的列向量

从输入层计算隐藏层



# 矩阵求导

X  
10元素  
 $A^{[0]}$

$W^{[1]}$ 、 $b^{[1]}$

隐藏层  
64神经元  
 $Z^{[1]} \rightarrow A^{[1]}$

$W^{[2]}$ 、 $b^{[2]}$

输出层  
1个神经元  
 $Z^{[2]} \rightarrow A^{[2]}$

损失函数J  
二元交叉熵

## 神经网络

- (1)  $Z^{[1]} = W^{[1]}X + b^{[1]} = (64 \times 10)(10 \times 1) + (64 \times 1) = (64 \times 1)$
- (2)  $A^{[1]} = \sigma(Z^{[1]}) = (64 \times 1)$
- (3)  $Z^{[2]} = W^{[2]}A^{[1]} + b^{[2]} = (1 \times 64)(64 \times 1) + (1 \times 1) = (1 \times 1)$
- (4)  $\hat{y} = A^{[2]} = \sigma(Z^{[2]}) = (1 \times 1)$
- 处理过程  $A^{[0]} \rightarrow Z^{[1]} \rightarrow A^{[1]} \rightarrow Z^{[2]} \rightarrow A^{[2]}$
- X即 $A^{[0]}$

有1个样本，每个样本为 $10 \times 1$ 的列向量

隐藏层的非线性传导

# 矩阵求导

X  
10元素  
 $A^{[0]}$

$W^{[1]}, b^{[1]}$

隐藏层  
64神经元  
 $Z^{[1]} \rightarrow A^{[1]}$

$W^{[2]}, b^{[2]}$

输出层  
1个神经元  
 $Z^{[2]} \rightarrow A^{[2]}$

损失函数J  
二元交叉熵

## 神经网络

- (1)  $Z^{[1]} = W^{[1]}X + b^{[1]} = (64*10)(10*1) + (64*1) = (64*1)$
- (2)  $A^{[1]} = \sigma(Z^{[1]}) = (64*1)$
- (3)  $Z^{[2]} = W^{[2]}A^{[1]} + b^{[2]} = (1*64)(64*1) + (1*1) = (1*1)$
- (4)  $\hat{y} = A^{[2]} = \sigma(Z^{[2]}) = (1*1)$
- 处理过程  $A^{[0]} \rightarrow Z^{[1]} \rightarrow A^{[1]} \rightarrow Z^{[2]} \rightarrow A^{[2]}$
- X即 $A^{[0]}$

有1个样本，每个样本为 $10 \times 1$ 的列向量

从隐藏层计算输出层

# 矩阵求导

X  
10元素  
 $A^{[0]}$

$W^{[1]}$ 、 $b^{[1]}$

隐藏层  
64神经元  
 $Z^{[1]} \rightarrow A^{[1]}$

$W^{[2]}$ 、 $b^{[2]}$

输出层  
1个神经元  
 $Z^{[2]} \rightarrow A^{[2]}$

损失函数J  
二元交叉熵

## 神经网络

- (1)  $Z^{[1]} = W^{[1]}X + b^{[1]} = (64*10)(10*1) + (64*1) = (64*1)$
- (2)  $A^{[1]} = \sigma(Z^{[1]}) = (64*1)$
- (3)  $Z^{[2]} = W^{[2]}A^{[1]} + b^{[2]} = (1*64)(64*1) + (1*1) = (1*1)$
- (4)  $\hat{y} = A^{[2]} = \sigma(Z^{[2]}) = (1*1)$
- 处理过程  $A^{[0]} \rightarrow Z^{[1]} \rightarrow A^{[1]} \rightarrow Z^{[2]} \rightarrow A^{[2]}$
- X即 $A^{[0]}$

有1个样本，每个样本为 $10 \times 1$ 的列向量

输出层的非线性传导

# 矩阵求导

X  
10元素  
 $A^{[0]}$

$W^{[1]}$ 、 $b^{[1]}$

隐藏层  
64神经元  
 $Z^{[1]} \rightarrow A^{[1]}$

$W^{[2]}$ 、 $b^{[2]}$

输出层  
1个神经元  
 $Z^{[2]} \rightarrow A^{[2]}$

损失函数J  
二元交叉熵

## 神经网络

- 处理过程  $A^{[0]} \rightarrow Z^{[1]} \rightarrow A^{[1]} \rightarrow Z^{[2]} \rightarrow A^{[2]}$
- X即 $A^{[0]}$
- 最后用 $A^{[2]}$ 构造损失函数，，注意 $A^{[2]}$ 即预测值 $\hat{y}$ 
  - 二值分类器(0/1)的交叉熵损失函数的形式为

$$J = -\frac{1}{n} ((Y \log(A^{[2]}) + (1 - Y) \log(1 - A^{[2]}))$$

- $Y = (1^*, \mathbf{1})$
- $n = 1$

1个样本，每个  
样本为 $10 \times 1$ 的  
列向量

根据损失函数计算损失值



# 矩阵求导

X  
10元素  
 $A^{[0]}$

$W^{[1]}, b^{[1]}$

隐藏层  
64神经元  
 $Z^{[1]} \rightarrow A^{[1]}$

$W^{[2]}, b^{[2]}$

输出层  
1个神经元  
 $Z^{[2]} \rightarrow A^{[2]}$

损失函数J  
二元交叉熵

## 神经网络

- (1)  $Z^{[1]} = W^{[1]}X + b^{[1]} = (64 \times 10)(10 \times 1) + (64 \times 1) = (64 \times 1)$
- (2)  $A^{[1]} = \sigma(Z^{[1]}) = (64 \times 1)$
- (3)  $Z^{[2]} = W^{[2]}A^{[1]} + b^{[2]} = (1 \times 64)(64 \times 1) + (1 \times 1) = (1 \times 1)$
- (4)  $\hat{y} = A^{[2]} = \sigma(Z^{[2]}) = (1 \times 1)$
- 处理过程  $A^{[0]} \rightarrow Z^{[1]} \rightarrow A^{[1]} \rightarrow Z^{[2]} \rightarrow A^{[2]}$
- 最后用  $A^{[2]}$  构造损失函数, , 注意  $A^{[2]}$  即预测值  $\hat{y}$ 
  - 二值分类器(0/1)的交叉熵损失函数的形式为
  - $J = -\frac{1}{n}((Y \log(A^{[2]}) + (1 - Y) \log(1 - A^{[2]})))$
- 计算损失函数对  $W^{[1]}, b^{[1]}, W^{[2]}, b^{[2]}$  的导数

$$\begin{aligned} dZ^{[2]} &= dA^{[2]} g'(Z^{[2]}) (1 \times 1) (1 \times 1) \\ dW^{[2]} &= \frac{dJ}{dW^{[2]}} = \frac{dJ}{dA^{[2]}} \frac{dA^{[2]}}{dZ^{[2]}} \frac{dZ^{[2]}}{dW^{[2]}} = \\ &\quad \frac{dJ}{dZ^{[2]}} \frac{dZ^{[2]}}{dW^{[2]}} \\ &= dZ^{[2]} (A^{[1]})^T \\ &\quad (1 \times 1)(1 \times 64) \end{aligned}$$

$$\begin{aligned} \frac{\partial a^T X b}{\partial X} &= ab^T \\ \frac{\partial a^T X^T b}{\partial X} &= ba^T \\ \frac{\partial a^T X a}{\partial X} &= \frac{\partial a^T X^T a}{\partial X} = aa^T \end{aligned}$$

$$\frac{dZ^{[2]}}{dW^{[2]}} = \frac{d(W^{[2]}A^{[1]} + b^{[2]})}{dW^{[2]}} = \frac{d(EW^{[2]}A^{[1]} + b^{[2]})}{dW^{[2]}} = E^T (A^{[1]})^T$$

E为单位矩阵

# 矩阵求导

X  
10元素  
 $A^{[0]}$

$W^{[1]}, b^{[1]}$

隐藏层  
64神经元  
 $Z^{[1]} \rightarrow A^{[1]}$

$W^{[2]}, b^{[2]}$

输出层  
1个神经元  
 $Z^{[2]} \rightarrow A^{[2]}$

损失函数J  
二元交叉熵

## 神经网络

- (1)  $Z^{[1]} = W^{[1]}X + b^{[1]} = (64 \times 10)(10 \times \mathbf{1}) + (64 \times \mathbf{1}) = (64 \times \mathbf{1})$
- (2)  $A^{[1]} = \sigma(Z^{[1]}) = (64 \times \mathbf{1})$
- (3)  $Z^{[2]} = W^{[2]}A^{[1]} + b^{[2]} = (\mathbf{1} \times 64)(64 \times \mathbf{1}) + (\mathbf{1} \times \mathbf{1}) = (\mathbf{1} \times \mathbf{1})$
- (4)  $\hat{y} = A^{[2]} = \sigma(Z^{[2]}) = (\mathbf{1} \times \mathbf{1})$
- 处理过程  $A^{[0]} \rightarrow Z^{[1]} \rightarrow A^{[1]} \rightarrow Z^{[2]} \rightarrow A^{[2]}$
- (5) 最后用  $A^{[2]}$  构造损失函数, , 注意  $A^{[2]}$  即预测值  $\hat{y}$ 
  - 二值分类器(0/1)的交叉熵损失函数的形式为
  - $J = -\frac{1}{n}((Y \log(A^{[2]}) + (1 - Y) \log(1 - A^{[2]})))$
- 计算损失函数对  $W^{[1]}, b^{[1]}, W^{[2]}, b^{[2]}$  的导数

$$\begin{aligned} \frac{dJ}{db^{[2]}} &= \frac{dJ}{dA^{[2]}} \frac{dA^{[2]}}{dZ^{[2]}} \frac{dZ^{[2]}}{db^{[2]}} \\ &= [A^{[2]} - Y][1] = [A^{[2]} - Y] \\ &= dZ^{[2]} \\ &= (\mathbf{1} \times \mathbf{1}) \end{aligned}$$

$$\begin{aligned} \frac{dJ}{dA^{[1]}} &= \frac{dJ}{dA^{[2]}} \frac{dA^{[2]}}{dZ^{[2]}} \frac{dZ^{[2]}}{dA^{[1]}} = \frac{dJ}{dZ^{[2]}} \frac{dZ^{[2]}}{dA^{[1]}} \\ &= dZ^{[2]} (W^{[2]})^T \text{ 即 } (\mathbf{W}^{[2]})^T dZ^{[2]} \\ &= (64 \times \mathbf{1})(\mathbf{1} \times \mathbf{1}) \end{aligned}$$

$$\frac{dZ^{[2]}}{dA^{[1]}} = \frac{d(W^{[2]}A^{[1]} + b^{[2]})}{dA^{[1]}} = (W^{[2]})^T$$

# 矩阵求导

X  
10元素  
 $A^{[0]}$

$W^{[1]}, b^{[1]}$

隐藏层  
64神经元  
 $Z^{[1]} \rightarrow A^{[1]}$

$W^{[2]}, b^{[2]}$

输出层  
1个神经元  
 $Z^{[2]} \rightarrow A^{[2]}$

损失函数J  
二元交叉熵

## 神经网络

– (1)  $Z^{[1]} = W^{[1]}X + b^{[1]} = (64 \times 10)(10 \times \mathbf{1}) + (64 \times \mathbf{1}) = (64 \times \mathbf{1})$

– (2)  $A^{[1]} = \sigma(Z^{[1]}) = (64 \times \mathbf{1})$

– (3)  $Z^{[2]} = W^{[2]}A^{[1]} + b^{[2]} = (\mathbf{1} \times 64)(64 \times \mathbf{1}) + (\mathbf{1} \times \mathbf{1}) = (\mathbf{1} \times \mathbf{1})$

– (4)  $\hat{y} = A^{[2]} = \sigma(Z^{[2]}) = (\mathbf{1} \times \mathbf{1})$

– 处理过程  $A^{[0]} \rightarrow Z^{[1]} \rightarrow A^{[1]} \rightarrow Z^{[2]} \rightarrow A^{[2]}$

– (5) 最后用  $A^{[2]}$  构造损失函数, , 注意  $A^{[2]}$  即预测值  $\hat{y}$

• 二值分类器(0/1)的交叉熵损失函数的形式为

•  $J = -\frac{1}{n} ((Y \log(A^{[2]}) + (1 - Y) \log(1 - A^{[2]})))$

– 计算损失函数对  $W^{[1]}, b^{[1]}, W^{[2]}, b^{[2]}$  的导数

$$dZ^{[1]} = dA^{[1]} g'(Z^{[1]})$$

$$(64 \times \mathbf{1}) (64 \times \mathbf{1})$$

$$dW^{[1]} = \frac{dJ}{dW^{[1]}} = \frac{dJ}{dA^{[2]}} \frac{dA^{[2]}}{dZ^{[2]}} \frac{dZ^{[2]}}{dA^{[1]}} \frac{dA^{[1]}}{dZ^{[1]}} \frac{dZ^{[1]}}{dW^{[1]}}$$

$$= \frac{dJ}{dZ^{[1]}} \frac{dZ^{[1]}}{dW^{[1]}}$$

$$= dZ^{[1]} (A^{[0]})^T$$

$$(64 \times \mathbf{1}) (\mathbf{1} \times 10)$$

$$\frac{\partial \mathbf{a}^T \mathbf{X} \mathbf{b}}{\partial \mathbf{X}} = \mathbf{a} \mathbf{b}^T$$

$$\frac{\partial \mathbf{a}^T \mathbf{X}^T \mathbf{b}}{\partial \mathbf{X}} = \mathbf{b} \mathbf{a}^T$$

$$\frac{\partial \mathbf{a}^T \mathbf{X} \mathbf{a}}{\partial \mathbf{X}} = \frac{\partial \mathbf{a}^T \mathbf{X}^T \mathbf{a}}{\partial \mathbf{X}} = \mathbf{a} \mathbf{a}^T$$

$$\frac{dZ^{[1]}}{dW^{[1]}} = \frac{d(W^{[1]}A^{[0]} + b^{[1]})}{dW^{[1]}} = \frac{d(EW^{[1]}A^{[0]} + b^{[1]})}{dW^{[1]}} = E^T (A^{[0]})^T$$

E为单位矩阵

# 矩阵求导

X  
10元素  
 $A^{[0]}$

$W^{[1]}$ 、 $b^{[1]}$

隐藏层  
64神经元  
 $Z^{[1]} \rightarrow A^{[1]}$

$W^{[2]}$ 、 $b^{[2]}$

输出层  
1个神经元  
 $Z^{[2]} \rightarrow A^{[2]}$

损失函数J  
二元交叉熵

## 神经网络

- (1)  $Z^{[1]} = W^{[1]}X + b^{[1]} = (64 \times 10)(10 \times \mathbf{1}) + (64 \times \mathbf{1}) = (64 \times \mathbf{1})$
- (2)  $A^{[1]} = \sigma(Z^{[1]}) = (64 \times \mathbf{1})$
- (3)  $Z^{[2]} = W^{[2]}A^{[1]} + b^{[2]} = (\mathbf{1} \times 64)(64 \times \mathbf{1}) + (\mathbf{1} \times \mathbf{1}) = (\mathbf{1} \times \mathbf{1})$
- (4)  $\hat{y} = A^{[2]} = \sigma(Z^{[2]}) = (\mathbf{1} \times \mathbf{1})$
- 处理过程  $A^{[0]} \rightarrow Z^{[1]} \rightarrow A^{[1]} \rightarrow Z^{[2]} \rightarrow A^{[2]}$
- (5) 最后用  $A^{[2]}$  构造损失函数，，注意  $A^{[2]}$  即预测值  $\hat{y}$ 
  - 二值分类器(0/1)的交叉熵损失函数的形式为
  - $J = -\frac{1}{n}((Y \log(A^{[2]}) + (1 - Y) \log(1 - A^{[2]})))$
- 计算损失函数对  $W^{[1]}$ 、 $b^{[1]}$ 、 $W^{[2]}$ 、 $b^{[2]}$  的导数

$$\begin{aligned} db^{[1]} &= \frac{dJ}{db^{[1]}} = \\ \frac{dJ}{dA^{[2]}} \frac{dA^{[2]}}{dZ^{[2]}} \frac{dZ^{[2]}}{dA^{[1]}} \frac{dA^{[1]}}{dZ^{[1]}} \frac{dZ^{[1]}}{db^{[1]}} &= \frac{dJ}{dZ^{[1]}} \frac{dZ^{[1]}}{db^{[1]}} = \\ \frac{dZ^{[1]}}{db^{[1]}} [1] &= \\ dZ^{[1]} &= \\ (64 \times \mathbf{1}) \end{aligned}$$



# 矩阵求导



# 矩阵求导

- NMF梯度 (矩阵求导)
- 假设我们把V分解为W和H
- $L = \min \frac{1}{2} ||V - WH||^2$
- $\frac{\partial L}{\partial w_{ik}} = -[(V - WH)H^T]_{ik}$
- $\frac{\partial L}{\partial h_{kj}} = -[W^T(V - WH)]_{kj}$

Frobenius norm

$$\frac{\partial}{\partial \mathbf{X}} ||\mathbf{X}||_F^2 = \frac{\partial}{\partial \mathbf{X}} \text{Tr}(\mathbf{X}\mathbf{X}^H) = 2\mathbf{X}$$

$$||\mathbf{A}||_F = \sqrt{\sum_{ij} |A_{ij}|^2} = \sqrt{\text{Tr}(\mathbf{A}\mathbf{A}^H)} \quad (\text{Frobenius})$$

$$\begin{aligned} (V - WH)(V - WH)^T &= \\ (V - WH)(V^T - H^T W^T) &= \\ VV^T - WHV^T - VH^T W^T + WHH^T W^T &= \\ \text{对着} W \text{求导, 得到} &= \\ 0 - VH^T - VH^T + WHH^T + WHH^T &= \\ -2(V - WH)H^T & \end{aligned}$$

$$WHH^T W^T$$

$$WHH^T W^T$$

# 矩阵求导

- NMF梯度 (矩阵求导)
- 假设我们把V分解为W和H
- $L = \min \frac{1}{2} ||V - WH||^2$
- $\frac{\partial L}{\partial w_{ik}} = -[(V - WH)H^T]_{ik}$
- $\frac{\partial L}{\partial h_{kj}} = -[W^T(V - WH)]_{kj}$

Frobenius norm

$$\frac{\partial}{\partial \mathbf{X}} ||\mathbf{X}||_F^2 = \frac{\partial}{\partial \mathbf{X}} \text{Tr}(\mathbf{X}\mathbf{X}^H) = 2\mathbf{X}$$

$$||\mathbf{A}||_F = \sqrt{\sum_{ij} |A_{ij}|^2} = \sqrt{\text{Tr}(\mathbf{A}\mathbf{A}^H)} \quad (\text{Frobenius})$$

$$\begin{aligned} (V - WH)^T (V - WH) &= \\ (V^T - H^T W^T) (V - WH) &= \\ V^T V - H^T W^T V - V^T WH + H^T W^T WH & \\ \text{对着H求导, 得到} & \\ 0 - W^T V - W^T V + W^T WH + W^T WH & \\ = -2W^T(V - WH) & \end{aligned}$$

$$H^T W^T WH$$

$$H^T W^T WH$$



# 矩阵求导

