



分类：SVM（原问题加上核函数技巧与梯度下降算法）



覃雄派

分类：SVM（原问题加上核函数技巧与梯度下降算法）

• 准备工作：向量的点积



Basic operation on vectors in \mathbb{R}^n

5. Dot product

Consider vectors $\vec{a} = (a_1, a_2, \dots, a_n)$ and $\vec{b} = (b_1, b_2, \dots, b_n)$

Define dot product: $\vec{a} \cdot \vec{b} = a_1 b_1 + a_2 b_2 + \dots + a_n b_n = \sum_{i=1}^n a_i b_i$

The law of cosines says that $\vec{a} \cdot \vec{b} = \|\vec{a}\|_2 \|\vec{b}\|_2 \cos \theta$ where θ is the angle between \vec{a} and \vec{b} . Therefore, when the vectors are perpendicular $\vec{a} \cdot \vec{b} = 0$.



$$\vec{a} \cdot \vec{b} = a_1 b_1 + a_2 b_2 + \dots + a_n b_n = \sum_{i=1}^n a_i b_i$$

- Property: $\vec{a} \cdot \vec{a} = a_1 a_1 + a_2 a_2 + \dots + a_n a_n = \|\vec{a}\|_2^2$
- In the classical regression equation $y = \vec{w} \cdot \vec{x} + b$ the response variable y is just a dot product of the vector representing patient characteristics (\vec{x}) and the regression weights vector (\vec{w}) which is common across all patients plus an offset b .

分类: SVM (原问题加上核函数技巧与梯度下降算法)

- 准备工作: 向量的第二范数


Basic operation on vectors in \mathbb{R}^n

4. Euclidian length or L2-norm

Consider a vector $\vec{a} = (a_1, a_2, \dots, a_n)$

Define the L2-norm: $\|\vec{a}\|_2 = \sqrt{a_1^2 + a_2^2 + \dots + a_n^2}$

We often denote the L2-norm without subscript, i.e. $\|\vec{a}\|$



L2-norm is a typical way to measure length of a vector; other methods to measure length also exist.

提纲




分类：SVM（原问题加上核函数技巧与梯度下降算法）

- 线性不可分问题与核函数
- 核函数及其优势
- 数据升维并线性可分实践
- 常用核函数
 - 高斯核函数的可视化
 - 理解高斯核函数
- 非线性可分数数据的SVM原问题求解
 - 原理
 - 实践

分类：SVM（原问题加上核函数技巧与梯度下降算法）

- 线性不可分问题与核函数
 - 假设平面上有两类数据点
 - 红色/蓝色
 - 我们无法通过一条直线
 - 把两类数据点分开
 - 这是一个线性不可分的问题




分类：SVM（原问题加上核函数技巧与梯度下降算法）

- 线性不可分问题与核函数
- 假设一个样本 \mathbf{x} （二维）
 - 记为 $\mathbf{x} = \{x_{i1}, x_{i2}\}$
- 给出一个如下变换 ϕ 如下
 - 把二维样本转换为三维样本


$$\Phi(\mathbf{x}_i) = \{x_{i1}, x_{i2}, \sqrt{2}x_{i1}x_{i2}\}$$

三维




分类：SVM（原问题加上核函数技巧与梯度下降算法）

- 线性不可分问题与核函数
- 假设一个样本 \mathbf{x} （二维）
 - 记为 $\mathbf{x} = \{x_{i1}, x_{i2}\}$
- 给出一个如下变换 ϕ 如下
 - 把二维样本转换为三维样本



$$\Phi(\mathbf{x}_i) = \{x_{i1}, x_{i2}, \sqrt{2}x_{i1}x_{i2}\}$$

- 对转换后的数据进行可视化
 - 结果如右图所示



可以看到，在3维空间，数据是线性可分的，或者基本线性可分的

分类：SVM（原问题加上核函数技巧与梯度下降算法）



分类：SVM（原问题加上核函数技巧与梯度下降算法）

- 为什么点积很重要
- SVM的原问题可以转换成对偶问题
 - 具体形式如下（在此不展开转换过程、以及对偶问题求解方法）
 - 该问题可以用二次规划方法求解
 - 可以看到样本点之间的点积是非常重要的操作

$$\max_{\alpha} \sum_i \alpha_i - \frac{1}{2} \sum_i \sum_j \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \cdot \mathbf{x}_j$$

$$\text{s.t. } \sum_i \alpha_i y_i = 0$$

SVM optimization problem: Benefits of using dual formulation

1) No need to access original data, need to access only dot products.

Objective function: $\sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i,j=1}^N \alpha_i \alpha_j y_i y_j \tilde{\mathbf{x}}_i \cdot \tilde{\mathbf{x}}_j$

Solution: $f(\tilde{\mathbf{x}}) = \text{sign}(\sum_{i=1}^N \alpha_i y_i \tilde{\mathbf{x}}_i \cdot \tilde{\mathbf{x}} + b)$

2) Number of free parameters is bounded by the number of support vectors and not by the number of variables (beneficial for high-dimensional problems).



E.g., if a microarray dataset contains 20,000 genes and 100 patients, then need to find only up to 100 parameters!

对偶问题有成熟解法SMO算法

分类：SVM（原问题加上核函数技巧与梯度下降算法）

- 我们可以
 - 1.把所有样本，利用某种函数 Φ 映射到高维空间，使其基本线性可分
 - 2.在高维空间，构建如下优化问题，进行求解

$$\begin{aligned} \max_{\alpha} \quad & \sum_i \alpha_i - \frac{1}{2} \sum_i \sum_j \alpha_i \alpha_j y_i y_j \Phi(\mathbf{x}_i)^T \cdot \Phi(\mathbf{x}_j) \\ \text{s.t.} \quad & \sum_i \alpha_i y_i = 0 \end{aligned}$$



分类：SVM（原问题加上核函数技巧与梯度下降算法）

- 核函数及其优势
- 假设有如下转换函数

$$\Phi(\mathbf{x}_i) = \{x_{i1}, x_{i2}, \sqrt{2}x_{i1}x_{i2}\}$$

- 为了计算两个样本升维以后的点积，有两种办法

- 办法1
- 1.每个样本先升维
- 2.再进行点积

$$\langle \Phi(\mathbf{x}_i), \Phi(\mathbf{x}_j) \rangle$$

$$\begin{aligned} \langle \Phi(\mathbf{x}_i), \Phi(\mathbf{x}_j) \rangle &= \langle \{x_{i1}^2, x_{i2}^2, \sqrt{2}x_{i1}x_{i2}\}, \{x_{j1}^2, x_{j2}^2, \sqrt{2}x_{j1}x_{j2}\} \rangle \\ &= x_{i1}^2x_{j1}^2 + x_{i2}^2x_{j2}^2 + 2x_{i1}x_{i2}x_{j1}x_{j2} \end{aligned}$$



分类：SVM（原问题加上核函数技巧与梯度下降算法）

- 核函数及其优势
- 假设有如下转换函数

$$\Phi(\mathbf{x}_i) = \{x_{i1}, x_{i2}, \sqrt{2}x_{i1}x_{i2}\}$$

- 为了计算两个样本升维以后的点积，有两种办法

- 办法2
- 1. 两个样本点积
- 2. 调用核函数进行转换

$$K(\mathbf{x}_i, \mathbf{x}_j) = \langle \mathbf{x}_i, \mathbf{x}_j \rangle^2$$

称为核函数

$$\begin{aligned}\langle \mathbf{x}_i, \mathbf{x}_j \rangle^2 &= \langle \{x_{i1}, x_{i2}\}, \{x_{j1}, x_{j2}\} \rangle^2 \\ &= (x_{i1}x_{j1} + x_{i2}x_{j2})^2 \\ &= x_{i1}^2x_{j1}^2 + x_{i2}^2x_{j2}^2 + 2x_{i1}x_{i2}x_{j1}x_{j2}\end{aligned}$$

两个方法的结果是相等的



分类：SVM（原问题加上核函数技巧与梯度下降算法）

• 比较两者的运算量

$$\Phi(\mathbf{x}_i) = \{x_{i1}, x_{i2}, \sqrt{2}x_{i1}x_{i2}\}$$

$$K(\mathbf{x}_i, \mathbf{x}_j) = \langle \mathbf{x}_i, \mathbf{x}_j \rangle^2$$

$$\begin{aligned} \langle \Phi(\mathbf{x}_i), \Phi(\mathbf{x}_j) \rangle &= \langle \{x_{i1}^2, x_{i2}^2, \sqrt{2}x_{i1}x_{i2}\}, \{x_{j1}^2, x_{j2}^2, \sqrt{2}x_{j1}x_{j2}\} \rangle \\ &= x_{i1}^2x_{j1}^2 + x_{i2}^2x_{j2}^2 + 2x_{i1}x_{i2}x_{j1}x_{j2} \end{aligned}$$

$$\begin{aligned} \langle \mathbf{x}_i, \mathbf{x}_j \rangle^2 &= \langle \{x_{i1}, x_{i2}\}, \{x_{j1}, x_{j2}\} \rangle^2 \\ &= (x_{i1}x_{j1} + x_{i2}x_{j2})^2 \\ &= x_{i1}^2x_{j1}^2 + x_{i2}^2x_{j2}^2 + 2x_{i1}x_{i2}x_{j1}x_{j2} \end{aligned}$$

1. 两个平方+一个乘法
2. 两个平方+一个乘法
3. 三个乘法+两个加法

共11个操作

1. 两个乘法
2. 一个加法
3. 一个平方

共4个操作

节省计算开销，达到同样效果

分类：SVM（原问题加上核函数技巧与梯度下降算法）

- 比较两者的运算量

$$\Phi(\mathbf{x}_i) = \{x_{i1}, x_{i2}, \sqrt{2}x_{i1}x_{i2}\}$$

$$K(\mathbf{x}_i, \mathbf{x}_j) = \langle \mathbf{x}_i, \mathbf{x}_j \rangle^2$$

$$\begin{aligned} \langle \Phi(\mathbf{x}_i), \Phi(\mathbf{x}_j) \rangle &= \langle \{x_{i1}^2, x_{i2}^2, \sqrt{2}x_{i1}x_{i2}\}, \{x_{j1}^2, x_{j2}^2, \sqrt{2}x_{j1}x_{j2}\} \rangle \\ &= x_{i1}^2x_{j1}^2 + x_{i2}^2x_{j2}^2 + 2x_{i1}x_{i2}x_{j1}x_{j2} \end{aligned}$$

$$\begin{aligned} \langle \mathbf{x}_i, \mathbf{x}_j \rangle^2 &= \langle \{x_{i1}, x_{i2}\}, \{x_{j1}, x_{j2}\} \rangle^2 \\ &= (x_{i1}x_{j1} + x_{i2}x_{j2})^2 \\ &= x_{i1}^2x_{j1}^2 + x_{i2}^2x_{j2}^2 + 2x_{i1}x_{i2}x_{j1}x_{j2} \end{aligned}$$

- 高维问题的求解，无须对向量进行升维

$$\begin{aligned} \max_{\alpha} \quad & \sum_i \alpha_i - \frac{1}{2} \sum_i \sum_j \alpha_i \alpha_j y_i y_j \Phi(\mathbf{x}_i)^T \cdot \Phi(\mathbf{x}_j) \\ \text{s.t.} \quad & \sum_i \alpha_i y_i = 0 \end{aligned}$$

$$\begin{aligned} \max_{\alpha} \quad & \sum_i \alpha_i - \frac{1}{2} \sum_i \sum_j \alpha_i \alpha_j y_i y_j K(\mathbf{x}_i, \mathbf{x}_j) \\ \text{s.t.} \quad & \sum_i \alpha_i y_i = 0 \end{aligned}$$

节省计算开销，达到同样效果

甚至无需构造转换函数 ϕ

分类：SVM（原问题加上核函数技巧与梯度下降算法）





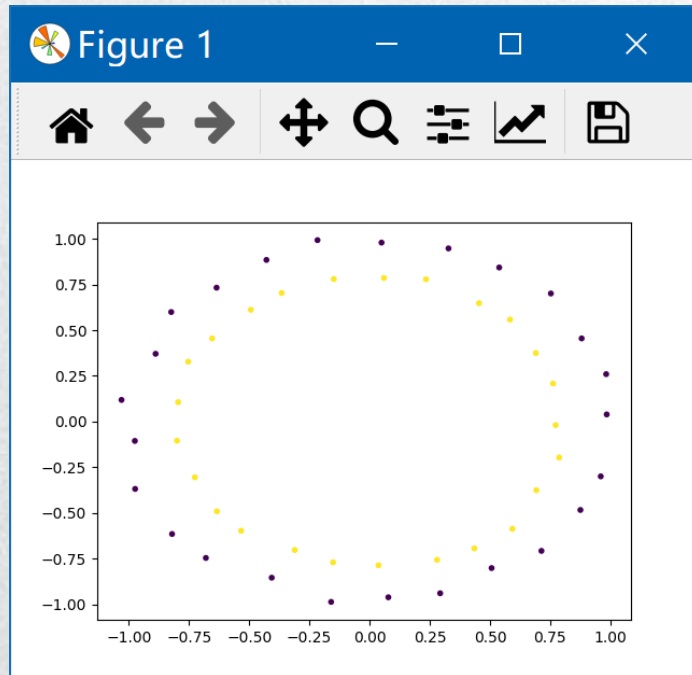
分类：SVM（原问题加上核函数技巧与梯度下降算法）

- 数据升维与线性可分实践

名称	类型	大小	修改日期
 03kernel_2d_3d(2).py	Python File	2 KB	2021/10/31 12:35

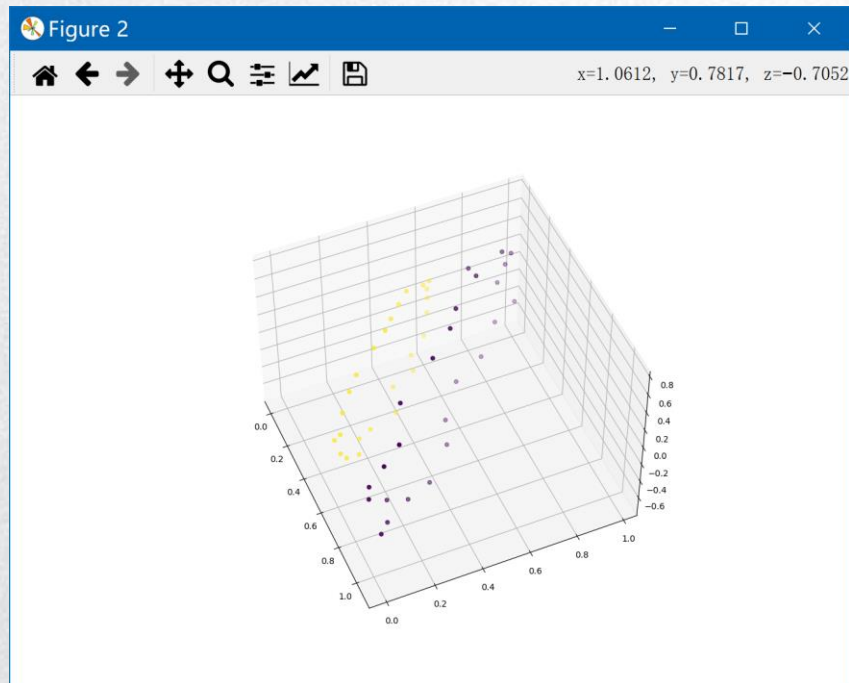
分类：SVM（原问题加上核函数技巧与梯度下降算法）

- 数据升维与线性可分实践
 - 2维空间数据点



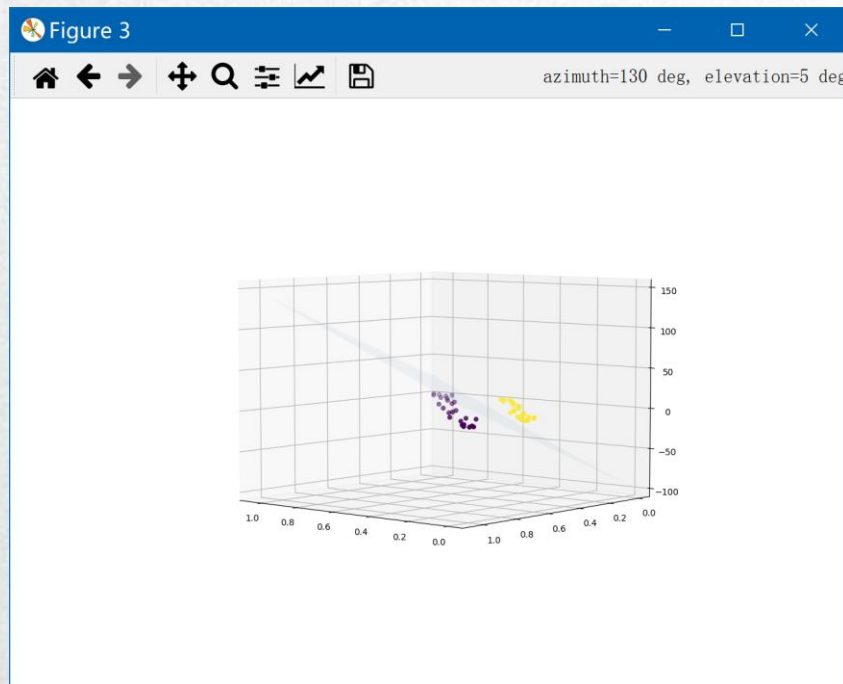
分类：SVM（原问题加上核函数技巧与梯度下降算法）

- 数据升维与线性可分实践
 - 2维空间数据点
 - 升维到3维空间



分类：SVM（原问题加上核函数技巧与梯度下降算法）

- 数据升维与线性可分实践
 - 2维空间数据点
 - 升维到3维空间
 - 线性可分和分类超平面
 - （拖动鼠标转动才能看清楚）



分类：SVM（原问题加上核函数技巧与梯度下降算法）



分类：SVM（原问题加上核函数技巧与梯度下降算法）

常用的核函数

- 如右图所示
- 核函数一般用K表示，K为Kernel的缩写
- 注意和前文所述转换函数 Φ 不是一回事
- （后文继续）
- 部分核函数的具体形式列举如下

Popular kernels

A kernel is a dot product in *some* feature space:

$$K(\vec{x}_i, \vec{x}_j) = \Phi(\vec{x}_i) \cdot \Phi(\vec{x}_j)$$

Examples:

$$K(\vec{x}_i, \vec{x}_j) = \vec{x}_i \cdot \vec{x}_j$$

Linear kernel

$$K(\vec{x}_i, \vec{x}_j) = \exp(-\gamma \|\vec{x}_i - \vec{x}_j\|^2)$$

Gaussian kernel

$$K(\vec{x}_i, \vec{x}_j) = \exp(-\gamma \|\vec{x}_i - \vec{x}_j\|)$$

Exponential kernel

$$K(\vec{x}_i, \vec{x}_j) = (p + \vec{x}_i \cdot \vec{x}_j)^q$$

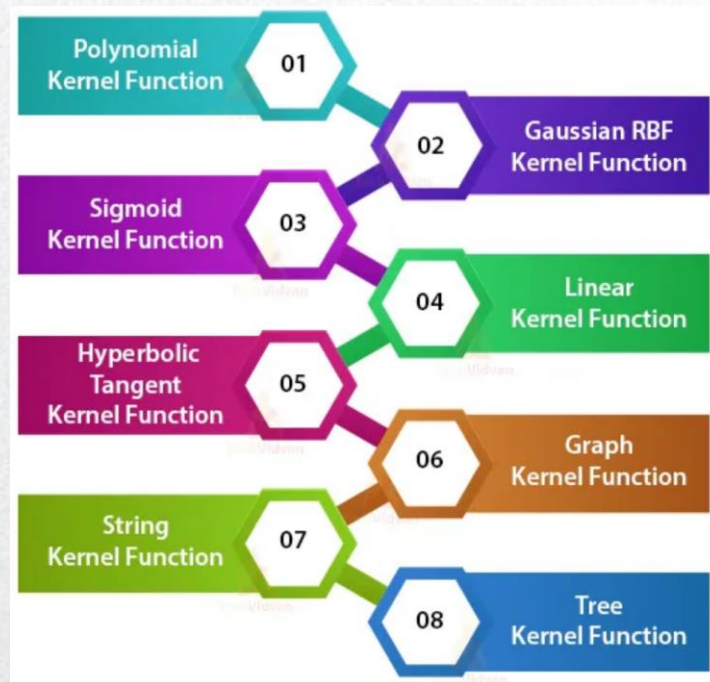
Polynomial kernel

$$K(\vec{x}_i, \vec{x}_j) = (p + \vec{x}_i \cdot \vec{x}_j)^q \exp(-\gamma \|\vec{x}_i - \vec{x}_j\|^2)$$

Hybrid kernel

$$K(\vec{x}_i, \vec{x}_j) = \tanh(k\vec{x}_i \cdot \vec{x}_j - \delta)$$

Sigmoidal



分类：SVM（原问题加上核函数技巧与梯度下降算法）

- 常用的核函数
- 核函数都具有这样的性质

- 两个向量 \mathbf{x}_i 和 \mathbf{x}_j

$$\Phi(\mathbf{x}_i) = \{x_{i1}, x_{i2}, \sqrt{2}x_{i1}x_{i2}\}$$

- 经过转换函数升维以后的点积

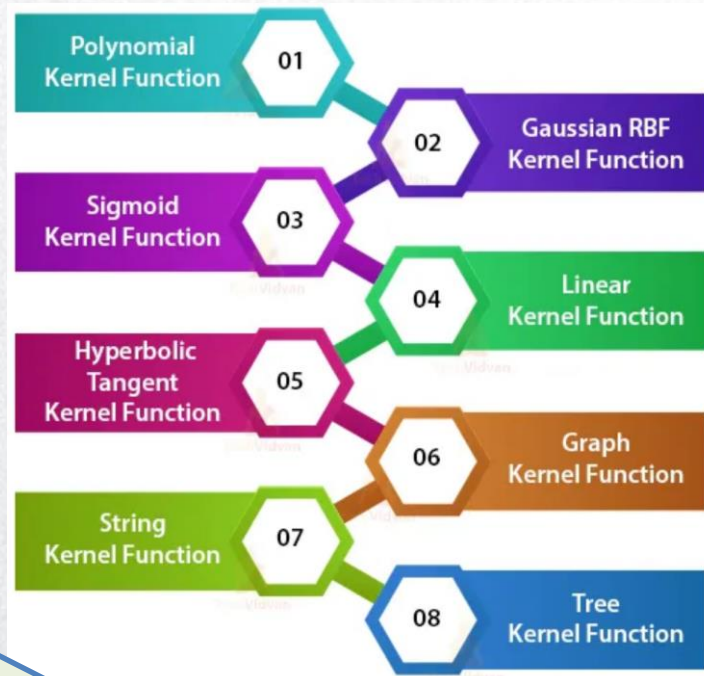
$$\begin{aligned} \langle \Phi(\mathbf{x}_i), \Phi(\mathbf{x}_j) \rangle &= \langle \{x_{i1}^2, x_{i2}^2, \sqrt{2}x_{i1}x_{i2}\}, \{x_{j1}^2, x_{j2}^2, \sqrt{2}x_{j1}x_{j2}\} \rangle \\ &= x_{i1}^2x_{j1}^2 + x_{i2}^2x_{j2}^2 + 2x_{i1}x_{i2}x_{j1}x_{j2} \end{aligned}$$

- 等于

- 两个向量 \mathbf{x}_i 和 \mathbf{x}_j 的点积代入核函数的结果

$$K(\mathbf{x}_i, \mathbf{x}_j) = \langle \mathbf{x}_i, \mathbf{x}_j \rangle^2$$

$$\begin{aligned} \langle \mathbf{x}_i, \mathbf{x}_j \rangle^2 &= \langle \{x_{i1}, x_{i2}\}, \{x_{j1}, x_{j2}\} \rangle^2 \\ &= (x_{i1}x_{j1} + x_{i2}x_{j2})^2 \\ &= x_{i1}^2x_{j1}^2 + x_{i2}^2x_{j2}^2 + 2x_{i1}x_{i2}x_{j1}x_{j2} \end{aligned}$$



核函数的作用是平方

分类：SVM（原问题加上核函数技巧与梯度下降算法）



分类：SVM（原问题加上核函数技巧与梯度下降算法）

- 高斯核函数（Radial Basis Function，径向基核函数）
 - 具体形式如下

$$K(\mathbf{x}_i, \mathbf{x}_j) = \exp\left(-\frac{\|\mathbf{x}_i - \mathbf{x}_j\|^2}{2\sigma^2}\right)$$

- 计算过程是两个数据点的距离的平方
- 除以 $2\sigma^2$
- 取负数
- 计算自然数的幂

分类：SVM（原问题加上核函数技巧与梯度下降算法）

- 高斯核函数（Radial Basis Function，径向基核函数）


- 可视化效果
- 变形(gamma)
- 一维高斯函数

$$K(\mathbf{x}_i, \mathbf{x}_j) = \exp\left(-\frac{\|\mathbf{x}_i - \mathbf{x}_j\|^2}{2\sigma^2}\right) = \exp\left(-\gamma \|\mathbf{x}_i - \mathbf{x}_j\|^2\right)$$

$$g(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x - x_j)^2}{2\sigma^2}}$$

- 可视化

1维高斯函数
 $\mathbf{x}_j = 0$




总结：

- σ 越大， γ 越小，分布越宽
- σ 越小， γ 越大，分布越窄

分类：SVM（原问题加上核函数技巧与梯度下降算法）

• 高斯核函数（Radial Basis Function，径向基核函数）

- 可视化效果
- 一维高斯函数可视化




总结：

- σ 越大， γ 越小，分布越宽
- σ 越小， γ 越大，分布越窄



- 不同大小的gamma值
- 的分类效果如下图




分类：SVM（原问题加上核函数技巧与梯度下降算法）



分类：SVM（原问题加上核函数技巧与梯度下降算法）

- 理解高斯核函数
 - 假设有如下的一维数据
 - 数据共有两类
 - 三角形一类
 - 正方形一类
 - 特征就一个 x_1
 - 可见，它们不是线性可分的



分类：SVM（原问题加上核函数技巧与梯度下降算法）

理解高斯核函数

简单起见

- 以-2和1这两个数据点做Landmark，即l1和l2
- 创建核函数

- l表示landmark
- 核函数有两个
- 图像如绿色和蓝色虚线所示

$$\exp(-\gamma \| \mathbf{x} - \ell \|^2)$$

$$\gamma = 0.3$$

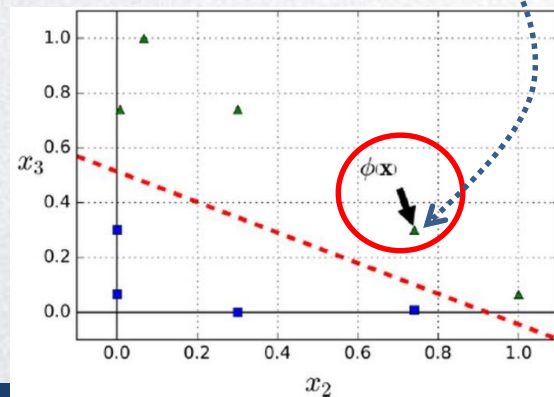

- 把-1这个数据点代入核函数

- 注意有两个landmark
- 有两个核函数
- 得到x2和x3

$$x_2 = \exp(-0.3 \times 1^2) \approx 0.74$$




$$x_3 = \exp(-0.3 \times 2^2) \approx 0.30$$

- {x2, x3}作为-1这个一维数据点的
- 升维到二维的坐标系，绘制如右下图所示



分类：SVM（原问题加上核函数技巧与梯度下降算法）




- 理解高斯核函数
 - 所有的一维数据点
 - 都利用同样的方法来进行升维



- 低维空间线性不可分的问题
- 转换为高维**线性可分**的问题

分类：SVM（原问题加上核函数技巧与梯度下降算法）

- 理解高斯核函数
 - 所有的一维数据点
 - 都利用同样的方法来进行升维



- 本实例，仅仅用了两个样本来做landmark（注意有几个landmark映射后就有几个维度）
- 在实际应用中，最简单的选取landmark的方法是选取样本个数，假设样本有N个，那么有N个landmark，我们映射后的维度就是N维
- 新建了更多的维度，使得数据被线性可分的机会大大增加

分类：SVM（原问题加上核函数技巧与梯度下降算法）





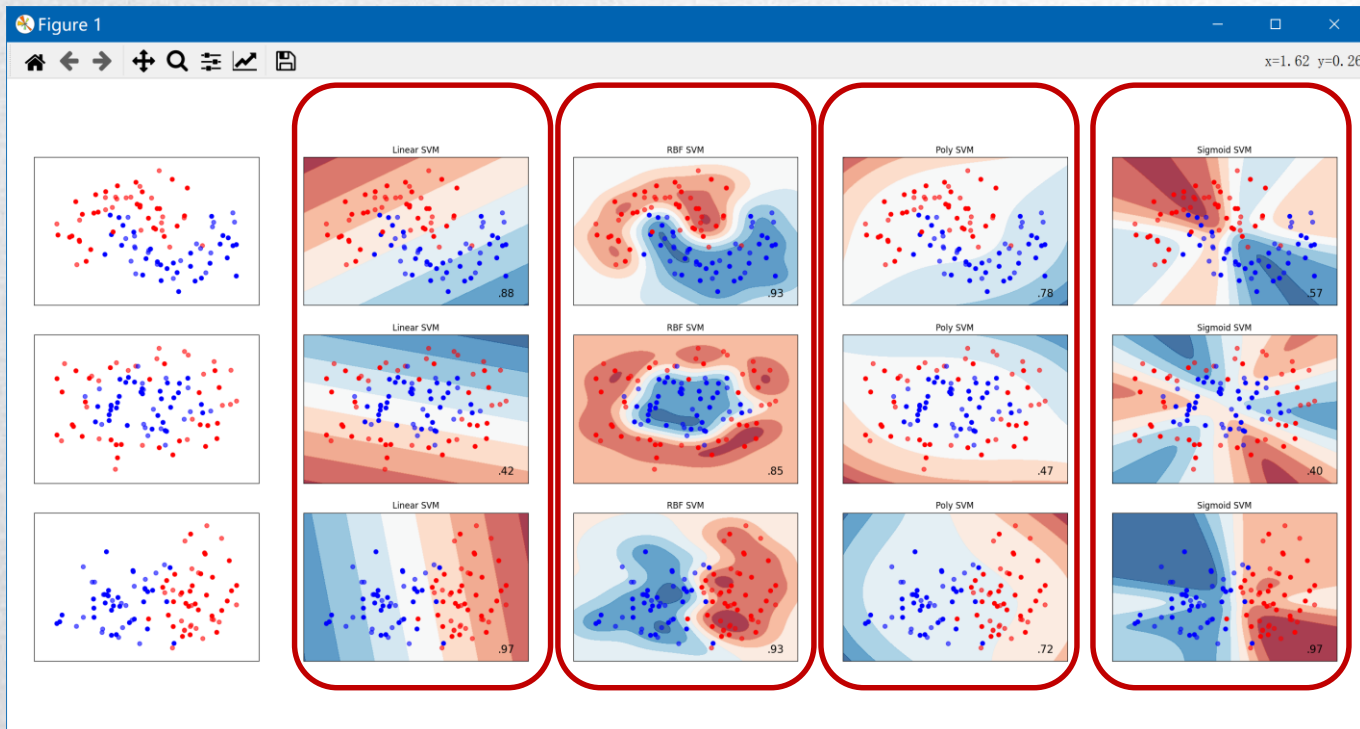
分类：SVM（原问题加上核函数技巧与梯度下降算法）

- 不同核函数效果比较（不同数据集）

Application (D:) > 2021-07-18 《数据科学概论》 new plan > 2022newPPT > 0303-分类：SVM（原问题加上核函数技巧与梯度下降算法）				搜索"030
名称	类型	大小	修改日期	
01compare-svm-kernels.py	Python File	4 KB	2021/11/10 12:50	

分类：SVM（原问题加上核函数技巧与梯度下降算法）

- 不同核函数效果比较（不同数据集）



分类：SVM（原问题加上核函数技巧与梯度下降算法）





分类：SVM（原问题加上核函数技巧与梯度下降算法）

- 非线性可分数据的SVM原问题求解
 - 回顾软间隔问题(线性可分或者基本线性可分问题)的目标函数和约束条件如下（请参考上一个PPT）：
 - $\min(\frac{1}{2} ||w||^2 + C \sum_{i=1}^n \xi_i)$
 - s.t. $y_i(w^T \cdot x_i + b) \geq 1 - \xi_i, i=1,2,\dots,n$
 - $\xi_i \geq 0, i=1,2,\dots,n$



分类：SVM（原问题加上核函数技巧与梯度下降算法）

- 非线性可分数据的SVM原问题求解
 - 回顾当我们采用Hinge Loss的时候，问题转化为如下优化问题（请参考上一个PPT）：
 - $\min \frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \max(0, 1 - y_i f(x_i))$
 - s.t. $y_i(w^T \cdot x_i + b) \geq 1 - \xi_i, i=1, 2, \dots, n$
 - $\xi_i \geq 0, i=1, 2, \dots, n$

分类：SVM（原问题加上核函数技巧与梯度下降算法）



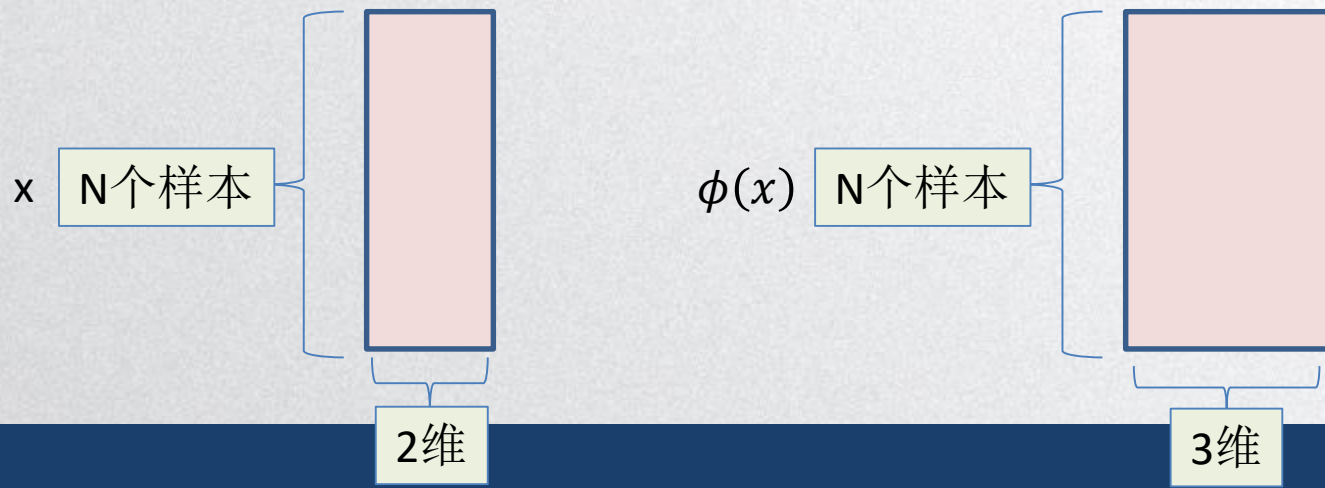


分类：SVM（原问题加上核函数技巧与梯度下降算法）

- 对于非线性可分的SVM问题，是不能直接用上述模型求解的，需要对数据进行升维
 - 转换函数 ϕ
 - 假设现在已经把数据转换到高维，即有低维空间的 x_1, x_2, \dots, x_n 等样本，对这些样本升维以后为 $\phi(x_1), \phi(x_2), \dots, \phi(x_n)$ ，注意 n 为样本个数
 - 把高维的各个特征的系数记为 β
 - β 表达为 $\phi(x_1), \phi(x_2), \dots, \phi(x_n)$ 的线性组合，即有 $\beta = \sum_{i=1}^n w_i \phi(x_i)$
 - 注意，这里的 w_i 不是软间隔问题的建模里面的 w 的各个分量，而是由 $\phi(x_1), \phi(x_2), \dots, \phi(x_n)$ 构成 β 的权重，共有 n 个
 - 在不至于引起混淆的情况下，姑且这么使用

分类：SVM（原问题加上核函数技巧与梯度下降算法）

- 对于非线性可分的SVM问题，是不能直接用上述模型求解的，需要对数据进行升维
 - 转换函数 ϕ
 - 假设低维空间为2维，高维空间为3维
 - x_1, x_2, \dots, x_n 都是 1×2 向量，那么 $\phi(x_1)$ 为 1×3 向量， $\phi(x_1)^T$ 为 3×1 向量
 - x 为 $n \times 2$ 向量， $\phi(x)$ 为 $n \times 3$ 向量， $\phi(x)^T$ 为 $3 \times n$ 向量



分类：SVM（原问题加上核函数技巧与梯度下降算法）

- 对于非线性可分的SVM问题，是不能直接用上述模型求解的，需要对数据进行升维

– 已知有 $\beta = \phi(x)^T w = (\phi(x_1)^T, \phi(x_2)^T, \dots, \phi(x_n)^T) \begin{pmatrix} w_1 \\ w_2 \\ \dots \\ w_n \end{pmatrix}$

– 此时，高维空间的目标函数为

– $L = \frac{1}{2} \beta^T \beta + C \sum_{i=1}^n \max(0, 1 - y_i(\beta^T \phi(x_i) + b))$



$$\begin{aligned} \min & \frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \max(0, 1 - y_i f(x_i)) \\ \text{s.t. } & y_i(w^T \cdot x_i + b) \geq 1 - \xi_i, i=1, 2, \dots, n \\ & \xi_i \geq 0, i=1, 2, \dots, n \end{aligned}$$



分类：SVM（原问题加上核函数技巧与梯度下降算法）

- 对于非线性可分的SVM问题，是不能直接用上述模型求解的，需要对数据进行升维
 - 把 $\beta = \phi(x)^T w$ 代入，对其进行简化如下
 - $L = \frac{1}{2} (\phi(x)^T w)^T \phi(x)^T w + C \sum_{i=1}^n \max(0, 1 - y_i ((\phi(x)^T w)^T \phi(x_i) + b))$
 - $= \frac{1}{2} w^T \phi(x) \phi(x)^T w + C \sum_{i=1}^n \max(0, 1 - y_i (w^T \phi(x) \phi(x_i) + b))$
 - $= \frac{1}{2} w^T K(x, x^T) w + C \sum_{i=1}^n \max(0, 1 - y_i (w^T K(x, x_i) + b))$

- 上述式子各个成分的维度为
- $(1*n) K(n*2*2*n) (n*1) + \max((1*1), (1*1)-(1*1)(1*n) K(n*2*2*1) + (1*1))$
- 这里的2指的是(上文)假设低维空间的维度为2



分类：SVM（原问题加上核函数技巧与梯度下降算法）

- 对于非线性可分的SVM问题，是不能直接用上述模型求解的，需要对数据进行升维

- 把 $\beta = \phi(x)^T w$ 代入，对其进行简化如下
- $\frac{1}{2} w^T K(x, x^T) w + C \sum_{i=1}^n \max(0, 1 - y_i (w^T K(x, x_i) + b))$

- 为了寻找最小值，需要针对参数 w 和 b 求偏导数
- 然后代入梯度下降公式，不断进行迭代即可

- $\frac{\partial L}{\partial w} = K(x, x^T) w - C \sum_{i=1, \xi_i \geq 0}^n y_i K(x, x_i)$

$\xi_i = 0$ 表示支持向量，
 $\xi_i > 0$ 表示分类错误

各个成分的维度为 $K(n \times 2 \times 2 \times n) (n \times 1) - (1 \times 1) K(n \times 2 \times 2 \times 1)$



分类：SVM（原问题加上核函数技巧与梯度下降算法）

- 对于非线性可分的SVM问题，是不能直接用上述模型求解的，需要对数据进行升维
 - 把 $\beta = \phi(x)^T w$ 代入，对其进行简化如下
 - $\frac{1}{2} w^T K(x, x^T) w + C \sum_{i=1}^n \max(0, 1 - y_i (w^T K(x, x_i) + b))$
 - 为了寻找最小值，需要针对参数 w 和 b 求偏导数
 - 然后代入梯度下降公式，不断进行迭代即可。
 - $\frac{\partial L}{\partial b} = -C \sum_{i=1, \xi_i \geq 0}^n y_i$
 - 各个成分的维度为(1*1)

$\xi_i = 0$ 表示支持向量，
 $\xi_i > 0$ 表示分类错误



分类：SVM（原问题加上核函数技巧与梯度下降算法）

- 对于非线性可分的SVM问题，是不能直接用上述模型求解的，需要对数据进行升维
 - 通过梯度下降算法迭代求解，求得w和b参数
 - $W = w - \eta \frac{\partial L}{\partial w}$
 - $b = b - \eta \frac{\partial L}{\partial b}$
 - η 为学习率



分类：SVM（原问题加上核函数技巧与梯度下降算法）

- 对于非线性可分的SVM问题，是不能直接用上述模型求解的，需要对数据进行升维
 - 最后，可以使用如下式子，预测样本 z 的类别
 - $\hat{y} = \text{sign}(\beta^T \phi(Z) + b)$
 - $= \text{sign}((\phi(x)^T w)^T \phi(Z) + b)$
 - $= \text{sign}(w^T \phi(x) \phi(Z) + b)$
 - $= \text{sign}(w^T K(x, z) + b)$
 - 各个成分的维度为 $(1*n) K(n*2)(2*1) + (1*1)$

分类：SVM（原问题加上核函数技巧与梯度下降算法）





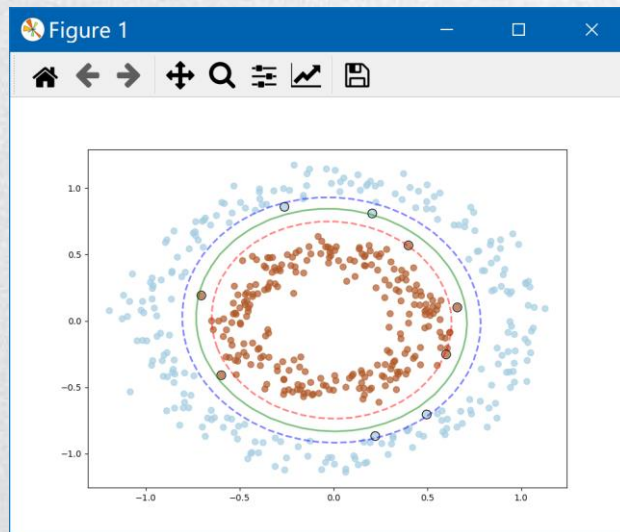
分类：SVM（原问题加上核函数技巧与梯度下降算法）

- SVM（原问题加上核函数技巧与梯度下降算法）
 - 实践（代码）

共享 查看				
« 2021-07-18 《数据科学概论》 new plan » 2022newPPT » 0302-分类：SVM（硬间隔、软间隔、梯度下降算法）		SVM-tutorial		
名称		类型	大小	修改日期
iris.csv		Microsoft Excel...	5 KB	2021/3/20 16:03
Linear_SVM_Soft_Margin_using_GD.py		Python File	4 KB	2021/7/17 16:39
NonLinearSVM_DualProblem.py		Python File	5 KB	2021/7/17 17:06
NonLinearSVM_PrimalProblem.py		Python File	6 KB	2021/7/17 17:05

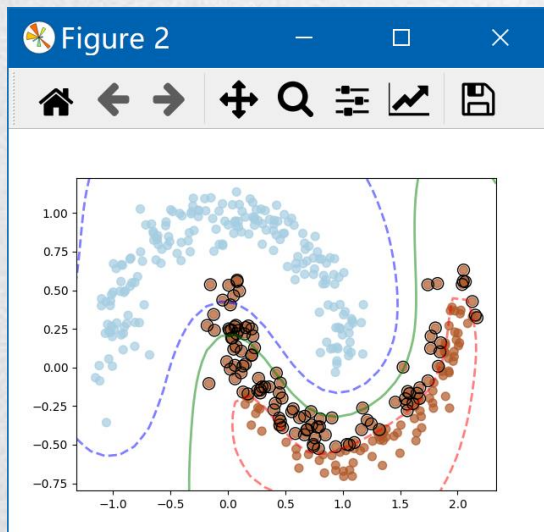
分类：SVM（原问题加上核函数技巧与梯度下降算法）

- SVM（原问题加上核函数技巧与梯度下降算法）
 - 实践（数据集1）



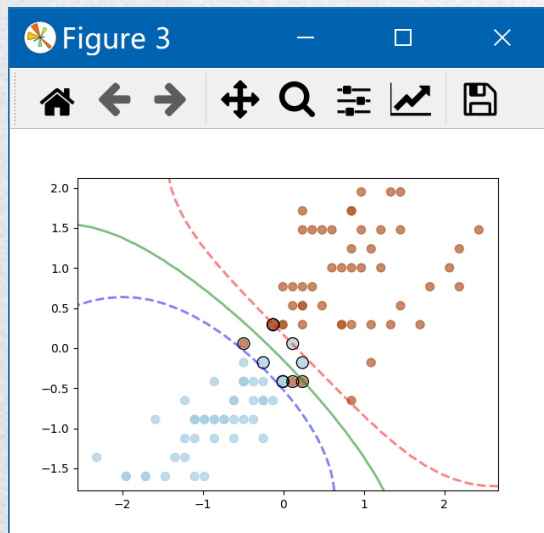
分类：SVM（原问题加上核函数技巧与梯度下降算法）

- SVM（原问题加上核函数技巧与梯度下降算法）
 - 实践（数据集2）



分类：SVM（原问题加上核函数技巧与梯度下降算法）

- SVM（原问题加上核函数技巧与梯度下降算法）
 - 实践（数据集3）



分类：SVM（原问题加上核函数技巧与梯度下降算法）

