



Hub & authority



覃雄派

提纲

- HITS算法
- HITS算法的应用
- HITS算法的不足
- HITS算法算法实践



Hub & authority

Hub & authority

- HITS(Hyperlink Induced Topic Search)算法
 - 是康奈尔大学的Jon Kleinberg 博士于1997年提出的
 - 这个算法是网页链接分析中非常重要的算法之一





Hub & authority

- HITS(Hyperlink Induced Topic Search)算法
 - Authority页面(权威页面)和Hub页面(枢纽页面)是HITS算法最基本的两个概念
 - 所谓Authority页面，是指与某个领域或者某个话题相关的高质量网页
 - 比如，在搜索引擎领域，谷歌、百度的首页就是该领域的高质量网页
 - 而在视频领域，YouTube、优酷、土豆等视频网站的首页，就是该领域的高质量网页
 - 而“Hub”页面，指的是包含了很多指向高质量“Authority”页面链接的网页





Hub & authority

- HITS(Hyperlink Induced Topic Search)算法
 - HITS算法的目的，是通过一个迭代计算过程，在海量的网页中，找到和用户查询相关的高质量的“Authority”页面和“Hub”页面
 - 其中，“Authority”页面，包含能够满足用户查询的高质量内容
 - 搜索引擎以这些网页为搜索结果，返回给用户

Hub & authority

- HITS(Hyperlink Induced Topic Search)算法
 - HITS算法的基本思想是，“Authority” 页面和 “Hub” 页面具有相互增强的关系
 - (1) 一个好的 “Authority” 页面会被很多好的 “Hub” 页面指向
 - (2) 一个好的 “Hub” 页面会指向很多好的 “Authority” 页面






Hub & authority

- HITS(Hyperlink Induced Topic Search)算法
 - 算法的执行过程包括三个大的步骤，分别是构造根集合、扩展根集合，以及迭代计算各个网页的Authority和Hub得分
- **(1) 构造根集合(Root)**
 - 将查询Q提交给基于关键字查询的检索系统，从返回结果页面集合中，取前n(比如n=200)个网页，作为根集合(Root Set)，记为Root
 - 由此可见，Root中的网页数量较少，这些网页是和查询Q相关的网页，Root中包含较多的权威(Authority)网页
 - 这些网页，以及网页之间的链接关系，构成了一个有向图 $G(V,E)$

Hub & authority

- HITS(Hyperlink Induced Topic Search)算法
 - 算法的执行过程包括三个大的步骤，分别是构造根集合、扩展根集合，以及迭代计算各个网页的 Authority和Hub得分
- (2) 扩展根集合(Base)
 - 在根集合Root的基础上，对网页集合进行扩充，构造集合Base
 - 扩充过程描述如下：凡是与根集内网页有直接链接指向关系的网页都被扩充到集合Base
 - 也就是，无论是有链接指向根集内页面，还是根集页面有链接指向的页面，都被扩充到扩展网页集合Base里
 - HITS算法将在这个扩展网页集合内寻找好的“Hub”页面与好的“Authority”页面



Hub & authority

- HITS(Hyperlink Induced Topic Search)算法
 - 算法的执行过程包括三个大的步骤，分别是构造根集合、扩展根集合，以及迭代计算各个网页的Authority和Hub得分
- **(3) 计算扩展集合(Base)中所有页面的Hub得分(枢纽度)和Authority得分(权威度)**

```
a0=1, h0=1 //a, h为向量，各个元素初始化为1，分别对应一个网页的
a得分和h得分
t = 1 //迭代时间步为1
do
{
  For each v in V
  {
    at(v) =  $\sum_{\langle w, v \rangle \in E} h_{t-1}(w)$ 
    ht(v) =  $\sum_{\langle v, w \rangle \in E} a_{t-1}(w)$ 
    at = at / |at|
    ht = ht / |ht|
    t = t + 1
  }
} while (|at - at-1| + |ht - ht-1| > ε)
Return (at, ht)
```

Hub & authority

- HITS(Hyperlink Induced Topic Search)算法
 - 算法的执行过程包括三个大的步骤，分别是构造根集合、扩展根集合，以及迭代计算各个网页的Authority和Hub得分
- **(3) 计算扩展集合(Base)中所有页面的Hub得分(枢纽度)和Authority得分(权威度)**

$a_0=1, h_0=1$ //a, h为向量，各个元素初始化为1，分别对应一个网页的a得分和h得分

$t = 1$ //迭代时间步为1

do

{

For each v in V

{

$$a_t(v) = \sum_{\langle w, v \rangle \in E} h_{t-1}(w)$$

$$h_t(v) = \sum_{\langle v, w \rangle \in E} a_{t-1}(w)$$

$$a_t = a_t / |a_t|$$

$$h_t = h_t / |h_t|$$

$$t = t + 1$$

}

} while ($|a_t - a_{t-1}| + |h_t - h_{t-1}| > \epsilon$)

Return (a_t, h_t)



Hub得分和Authority得分的更新方式

Hub & authority



Hub & authority

- HITS算法不仅应用在搜索引擎领域
 - 在其他领域也得到了借鉴和应用，并取得了很好的效果

- ◆ Search engine querying (speed is an issue).
- ◆ Finding web communities.
- ◆ Finding related pages.
- ◆ Populating categories in web directories.
- ◆ Citation analysis.

Hub & authority

- HITS算法不仅应用在搜索引擎领域
 - 在其他领域也得到了借鉴和应用，并取得了很好的效果

Communities on the Web

- ◆ A densely linked focused sub-graph of hubs and authorities is called a *community*.
- ◆ Over 100,000 emerging web communities have been discovered from a web crawl (a process called *trawling*).

Hub & authority





Hub & authority

- HITS算法的不足
- HITS算法也有一些不足，这需要在实际应用中加以注意。这些不足包括：
 - (1) 结构不稳定：当在已有的“扩充网页集合”内，添加或者删除个别网页，或者改变少数几个链接关系，那么HITS算法的排名结果，就会发生较大的改变



Hub & authority

- HITS算法的不足
- HITS算法也有一些不足，这需要在实际应用中加以注意。这些不足包括：
 - (2) 计算效率不高：首先HITS算法必须在接收到用户查询后实时进行计算，此外该算法需要进行多轮迭代计算，才能获得最终结果，其计算效率不高



Hub & authority

- HITS算法的不足
- HITS算法也有一些不足，这需要在实际应用中加以注意。这些不足包括：
 - (3) 主题漂移问题：如果在“扩展网页集合”里包含部分与查询主题无关的页面，而且这些页面之间有更多的相互链接指向，HITS算法很可能会给予这些无关网页很高的排名，导致搜索结果发生主题漂移；这种现象，称为“紧密链接社区现象” (Tightly Knit Community Effect)



Hub & authority

- HITS算法的不足
- HITS算法也有一些不足，这需要在实际应用中加以注意。这些不足包括：
 - (4) 容易被作弊者操纵排名结果：如作弊者可以建立一个网页，页面内容增加很多指向高质量网页或者著名网站的网址，这就是一个很好的Hub页面，之后作弊者在这个Hub页面制作网页链接指向作弊网页，搭个便车，于是可以提升作弊网页的Authority得分

Hub & authority





图数据入门、中心度

- 中心度计算Python实例分析

名称	类型	大小	修改日期 ^
 01qraph high school love.py	Python File	3 KB	2021/10/25 16:00

<https://aksakalli.github.io/2017/07/17/network-centrality-measures-and-their-visualization.html>



图数据入门、中心度

- 中心度计算Python实例分析
 - 绘制函数

```
1 import networkx as nx
2 import matplotlib.pyplot as plt
3 import matplotlib.colors as mcolors
4
5 def draw(G, pos, measures, measure_name, num):
6
7     plt.figure(num)
8     nodes = nx.draw_networkx_nodes(G, pos, node_size=250, cmap=plt.cm.plasma,
9                                     node_color=list(measures.values()),
10                                    nodelist=measures.keys())
11     nodes.set_norm(mcolors.SymLogNorm(linthresh=0.01, linscale=1, base=10))
12     # Labels = nx.draw_networkx_labels(G, pos)
13     edges = nx.draw_networkx_edges(G, pos)
14
15     plt.title(measure_name)
16     plt.colorbar(nodes)
17     plt.axis('off')
18     plt.show()
```



图数据入门、中心度

- 中心度计算Python实例分析
 - 图的创建函数

```
20 def school_dating_graph():
21     students = set(range(11))
22     G = nx.Graph()
23     G.name = "Simple Dating Graph"
24     G.add_nodes_from(students)
25     dating_rel = [(0,3), (1,3), (2,3), (3,4), (4,5), (4,9),
26                  (5,6), (6,7), (6,8), (6,9), (9,10)]
27     G.add_edges_from(dating_rel)
28     # You may want to try automatic layout
29     #pos = nx.spring_layout();
30     pos = {0: [0.1, 0.6], 1: [0.1, 0.5], 2: [0.1, 0.4], 3: [0.2, 0.5],
31           4: [0.3, 0.5], 5: [0.45, 0.7], 6: [0.6, 0.5], 7: [0.7, 0.6],
32           8: [0.7, 0.4], 9: [0.45, 0.3], 10: [0.45, 0.2]}
33     return G, pos
```

图数据入门、中心度

- 中心度计算Python实例分析
 - 计算Hub & Authority分值

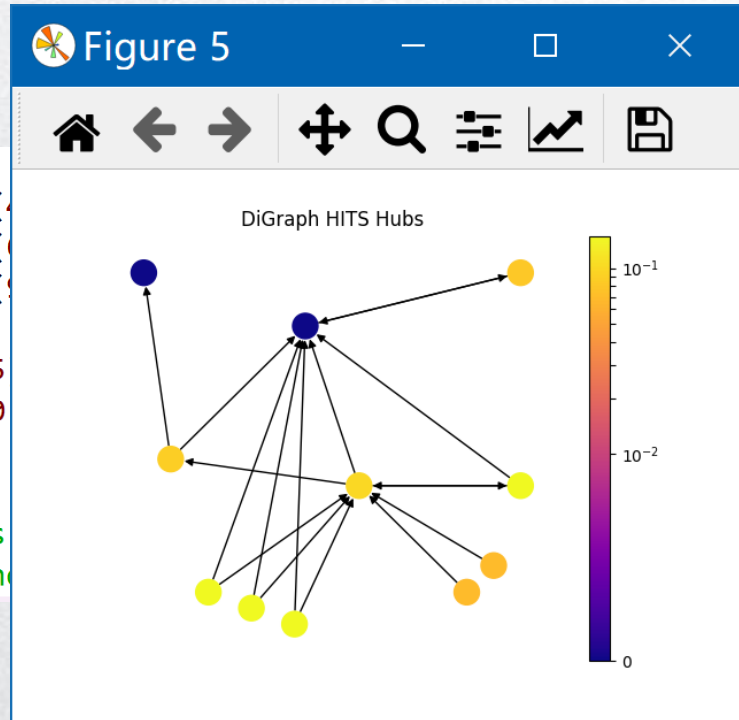
```
85 DiG = nx.DiGraph()
86 DiG.add_edges_from([(2, 3), (3, 2), (4, 1), (4, 2), (5, 2), (5, 4),
87                     (5, 6), (6, 2), (6, 5), (7, 2), (7, 5), (8, 2),
88                     (8, 5), (9, 2), (9, 5), (10, 5), (11, 5)])
89 dpos = {1: [0.1, 0.9], 2: [0.4, 0.8], 3: [0.8, 0.9], 4: [0.15, 0.55],
90         5: [0.5, 0.5], 6: [0.8, 0.5], 7: [0.22, 0.3], 8: [0.30, 0.27],
91         9: [0.38, 0.24], 10: [0.7, 0.3], 11: [0.75, 0.35]}
92
93 h,a = nx.hits(DiG)
94 draw(DiG, dpos, h, 'DiGraph HITS Hubs',5)
95 draw(DiG, dpos, a, 'DiGraph HITS Authorities',6)
```

图数据入门、中心度

- 中心度计算Python实例分析
 - 显示Hub & Authority分值

```

85 DiG = nx.DiGraph()
86 DiG.add_edges_from([(2, 3), (3, 2), (4, 3), (5, 6), (6, 2), (6, 3),
87                     (8, 5), (9, 2), (9, 3), (10, 3), (10, 5), (10, 6),
88                     (10, 8), (10, 9), (10, 10)])
89 dpos = {1: [0.1, 0.9], 2: [0.4, 0.8], 3: [0.5, 0.5], 4: [0.2, 0.7],
90         5: [0.5, 0.5], 6: [0.8, 0.5], 7: [0.3, 0.6], 8: [0.4, 0.7],
91         9: [0.38, 0.24], 10: [0.7, 0.3]}
92
93 h,a = nx.hits(DiG)
94 draw(DiG, dpos, h, 'DiGraph HITS Hubs')
95 draw(DiG, dpos, a, 'DiGraph HITS Authorities')
    
```



- ```

85 DiG = nx.DiGraph()
86 DiG.add_edges_from([(2, 3), (3, 2), (4, 1),
87 (5, 6), (6, 2), (6, 5),
88 (8, 5), (9, 2), (9, 5)])
89 dpos = {1: [0.1, 0.9], 2: [0.4, 0.8], 3: [0.7, 0.9],
90 5: [0.5, 0.5], 6: [0.8, 0.5], 7: [0.9, 0.5],
91 9: [0.38, 0.24], 10: [0.7, 0.3],
92 11: [0.5, 0.1], 12: [0.9, 0.1]}
93 h,a = nx.hits(DiG)
94 draw(DiG, dpos, h, 'DiGraph HITS Hubs',5)
95 draw(DiG, dpos, a, 'DiGraph HITS Authoriti

```



# Hub & authority



# Hub & authority

- Relation between HITS, PageRank and LSI
  - HITS algorithm
    - = running SVD on the hyperlink relation (source, target)
  - LSI algorithm
    - = running SVD on the relation (term, document)
  - PageRank on root set R
    - gives same ranking as the ranking of hubs as given by HITS

Mining the Web. Chakrabarti and Ramakrishnan



# Hub & authority

- PageRank vs HITS
  - PageRank advantage over HITS
    - Query-time cost is low
      - HITS: computes an eigenvector for every query
    - Less susceptible to localized link-spam
  - HITS advantage over PageRank
    - HITS ranking is sensitive to query
    - HITS has notion of hubs and authorities

- Topic-sensitive Page Ranking [Haveliwala 2003]
- Attempt to make Page Ranking query sensitive

